

PROGRAMA DE ASIGNATURA

ACTIVIDAD CURRICULAR:

Ciencia de Datos

Plan: I23

Área: Científico - Técnica

Bloque: Tecnología Aplicada

Nivel: 5º

Tipo: Electiva

Modalidad: Cuatrimestral

Carga Horaria Total: 60hs.reloj //80hs. cátedra

Carga Horaria Semanal: 4hs. reloj// 5hs. cátedra

COMPOSICIÓN DEL EQUIPO DOCENTE:

Docente: Dr.. Martin Palazzo

Ayudante: Dr. Nicolas Aguirre

Ayudante: Ing. Santiago Chas

FUNDAMENTACIÓN DE LA ASIGNATURA:

El objetivo de esta materia es ofrecer a los estudiantes una doble competencia, tanto de método científico como profesional, con herramientas para la utilización en industrias modernas, dinámicas y de alta complejidad. La industria en general se encuentra cambiando drásticamente desde el nacimiento de internet. La explosión de datos abre nuevas oportunidades a los ingenieros industriales para desarrollarse como profesionales del análisis de datos, optimización de sistemas y toma de decisiones en entornos de alta complejidad. Se busca formar al futuro ingeniero con las siguientes competencias:

Competencia metodológica en modelización: ofreciendo formación en enfoques de aprendizaje estadístico, ciencia de datos, reconocimiento de patrones e inteligencia artificial en contextos de Ingeniería Industrial (conocida como la cuarta revolución industrial según el World Economic Forum).

Las competencias desarrolladas por la formación se buscan en sectores industriales muy diversos (como lo demuestra la integración profesional de los estudiantes): energía, automotriz, química y petroquímica, logística, empresas especializadas en servicios e ingeniería.

Prepara a los estudiantes para sus estudios de posgrado, alineado con la propuesta académica de las maestría en Planificación y Operaciones Industriales que el departamento co-tutela con la UTT y con cualquier oferta académica que incluya análisis de datos e Inteligencia Artificial.

OBJETIVOS:

Objetivos Generales:

- Analizar datos con herramientas estadísticas (estadística descriptiva).
- Comprender los principales algoritmos de Aprendizaje Automático (Machine Learning) y su utilidad en cada caso.
- Realizar prácticas de baja complejidad con herramientas de programación avanzada (Python).
- Detectar oportunidades de aplicación en la industria en el contexto de la 4ta revolución industrial.
- Conocer modelos de aprendizaje automático en entornos de producción.

Objetivos específicos:

- Comprender las bases de la Ciencia de Datos y el Aprendizaje Automático y sus aplicaciones en entornos de Ingeniería Industrial.
- Utilizar un lenguaje de programación (Python) para obtener, limpiar y procesar datos.
- Utilizar herramientas de gestión de datos para almacenar y procesar datos localmente y en infraestructuras en la nube.
- Aplicar métodos estadísticos y de visualización para el análisis exploratorio de datos.
- Comunicar efectivamente los resultados de los análisis a través del uso de estadística descriptiva y técnicas de visualización.
- Implementar un modelo de aprendizaje automático con datos provenientes en contextos vinculados a la Ingeniería Industrial.

CONTENIDOS:

a) Contenidos Mínimos:

- Análisis Exploratorio de Datos
- Procesamiento y manejo de datos
- Visualización
- Modelos de clasificación
- Modelos de regresión
- Reducción de la dimensionalidad
- Redes neuronales

b) Contenidos Analíticos:

Unidad 1: Introducción a Ciencia de Datos y Construcción de modelos

Conceptos básicos: ciencia de datos, aprendizaje automático, reconocimiento de patrones, aprendizaje estadístico. Teoría del aprendizaje. Aprendizaje Supervisado, semi supervisado, no supervisado, aprendizaje por refuerzos. Función objetivo, instancias, clases, atributos. Hipótesis, espacio de hipótesis. Error fuera de la muestra. Sobreajuste. Validación del modelo.

Unidad 2: Análisis exploratorio de datos

Base de datos (consultas). Servicios en la nube (procesamiento y almacenamiento). Pre-procesamiento. Transformaciones de datos (normalización, auto-escalado). Generación y selección de características. Visualización de datos. Clustering. Valores atípicos. Separación de datos (entrenamiento, validación y prueba).

Unidad 3: Modelos Lineales

Regresión lineal (simple y múltiple). Regresión logística. Optimización. Método del gradiente descendente. Regularización (L1, L2, Red elástica). Clasificadores lineales. Representación de hipótesis. Regla de decisión. Detección de anomalías.

Unidad 4: Reducción de Dimensionalidad y aprendizaje no supervisado

Aprendizaje no supervisado. Técnicas de visualización de datos de alta dimensionalidad. Análisis y selección de componentes principales. Reconstrucción de representaciones comprimidas. Agrupamiento y clustering.

Unidad 5: Introducción a las Redes Neuronales

Hipótesis no lineales. Regresión. Clasificación multiclase. Funciones de costo. Propagación hacia atrás de errores (backpropagation). Técnicas de inicialización. Regularización.

DISTRIBUCIÓN DE LA CARGA HORARIA ENTRE ACTIVIDADES TEÓRICAS Y PRÁCTICAS:

Tipo de Actividad	Carga Horaria Total en Hs. Reloj	Carga Horaria Total en Hs. Cátedra
Teórica	28.5	38
Formación Práctica(Total)	18.75	25
Formación Experimental	7.5	10
Resolución de Problemas	7.5	10
Proyectos y Diseño	3.75	5
Práctica Supervisada	0	0

ESTRATEGIAS METODOLÓGICAS:

a) Modalidades de Enseñanza empleadas según tipo de actividad (Teórica-Práctica):

El curso se desarrolla mediante el dictado de clases teóricas y clases prácticas. Se realiza una presentación de introducción teórica al tema que luego se asocia a un proyecto práctico en el cual el alumno empieza a trabajar. Por cada tema teórico habrá una implementación práctica y una serie de ejercicios que relacionen los tópicos de la materia con Ingeniería Industrial. Con el avance del proyecto se abordan las restantes temáticas y dificultades. Las clases prácticas tienen un espacio de trabajo en software junto con trabajo en equipos, los alumnos avanzan con el proyecto, realizan consultas y reciben consejos y ampliación del tema por parte de los profesores.

b) Recursos didácticos para el desarrollo de las distintas actividades:

- Material didáctico sistematizado y presentaciones como guía de trabajo y estudio para el alumno.
- Guía de Ejercicios
- Medios audiovisuales de exposición en clase.
- Entorno de desarrollo integrado (IDE) con aplicación en Python (Jupyter, Spyder, IPython, etc).
- Bases de datos públicas.

EVALUACIÓN:

a) Evaluaciones parciales

Cantidad de instancias de evaluación:1(una)

Cantidad de recuperatorios:1(unos)

Consistirá en un trabajo donde se tenga que desarrollar el planteo de hipótesis, desarrollo de un análisis de datos e implementación de modelos de Aprendizaje Automático utilizando bases de datos públicas. La instancia de evaluación será basada en los temas vistos en las clases hasta el momento. La nota final será la nota del trabajo integral.

b) Evaluación final

El Examen Final será escrito, y podrá abarcar todos los temas del Programa Analítico. La nota mínima de aprobación será de 6 (seis).

c) Aprobación directa

El estudiante podrá acceder a la Aprobación Directa según la normativa vigente.

ARTICULACIÓN HORIZONTAL Y VERTICAL CON OTRAS ASIGNATURAS:

Por las herramientas y conceptos básicos que se requieren para esta materia electiva se da una articulación vertical con Probabilidad y Estadística, Análisis Matemático, Análisis Numérico y Cálculo Avanzado, Investigación Operativa e Informática I y II (por sus herramientas otorgadas).

Se logra una articulación horizontal con todas aquellas materias en las cuales sus problemas prácticos en la actividad empresarial requieran el análisis de grandes cantidades de datos. Los casos son diversos pero pueden surgir en Ciencias de los Materiales, Economía, Comercialización, Procesos Industriales, Finanzas, Logística, Simulación, Sistemas de Gestión, Robótica Industrial, etc.

CRONOGRAMA ESTIMADO DE CLASES:

Unidad Temática	Duración en Hs. Cátedra
1	10
2	20
3	20
4	10
5	10
Parciales	10

BIBLIOGRAFÍA OBLIGATORIA:

- C. M. Bishop, Pattern recognition and machine learning. New York: Springer, 2006.
- T. Hastie, R. Tibshirani, J. H. Friedman, The Elements of Statistical Learning, Springer, 2001.
- I. Goodfellow, Y. Bengio, A. Courville, Deep Learning, MIT Press. 2016.
- T. M. Mitchell, Machine Learning. New York: McGraw-Hill, 1997.

BIBLIOGRAFÍA COMPLEMENTARIA:

- Hands on Machine Learning and scikit learn
- S. Theodoridis and K. Koutroumbas, Pattern recognition, 4. ed. Amsterdam: Elsevier Acad. Press, 2009.
- K. P. Murphy, Machine learning: a probabilistic perspective. Cambridge, Mass.: MIT Press, 2012.
- Y. S. Abu-Mostafa, M. Magdon-Ismail, and H.-T. Lin, Learning from data: a short course. S.l.: AMLbook.com, 2012.
- P. R. Norvig and S. A. Intelligence, A modern approach. Prentice Hall, 2002.
- D. Koller and N. Friedman, Probabilistic graphical models: principles and techniques. Cambridge, MA: MIT Press, 2009.
- J. Pearl and others, Models, reasoning and inference. Cambridge University Press Cambridge, UK:, 2000.
- G. James, D. Witten, T. Hastie, and R. Tibshirani, An Introduction to Statistical Learning, vol. 103. New York, NY: Springer New York, 2013.
- V. N. Vapnik, Statistical learning theory. New York: Wiley, 1998.
- G. Casella and R. L. Berger, Statistical inference, 2nd ed. Australia

- E. L. Lehmann and J. P. Romano, Testing statistical hypotheses, 3rd ed. New York: Springer, 2005.
- T. H. Cormen and T. H. Cormen, Eds., Introduction to algorithms, 2nd ed. Cambridge, Mass: MIT Press,

CORRELATIVAS:

Para Cursar: **Cursadas:** Investigación Operativa.

Aprobadas: Análisis numérico y cálculo avanzado, Informática II.

Para Aprobar: **Aprobadas:** Investigación Operativa.